

Cancer du Poumon et Facteurs de Risque Environnementaux

*Analyse Temporelle et Socio-économique de l'Impact
du Tabagisme et de la Pollution Atmosphérique*

Présenté par :

Louaï HAMLAT

Noémie HATCHUEL

1 Introduction et Problématique

1.1 Contexte de Santé Publique

Le cancer du poumon constitue aujourd’hui la première cause de mortalité par cancer au monde, avec 1,8 millions de décès annuels, dont 30 000 en France. Sa létalité dépasse celle des cancers du sein, du côlon et de la prostate réunis. Malgré une prise de conscience croissante des dangers du tabagisme et une diminution progressive de sa prévalence dans de nombreux pays développés, l’incidence du cancer du poumon demeure préoccupante. Cette persistance soulève une question fondamentale : d’autres facteurs environnementaux, notamment la pollution atmosphérique, jouent-ils un rôle plus important que celui traditionnellement admis ?

1.2 Question de Recherche

Cette étude vise à analyser la prévalence mondiale du cancer du poumon et à explorer ses corrélations avec deux facteurs de risque majeurs : le tabagisme et la pollution atmosphérique (particules fines PM_{2.5}). L’objectif central est de déterminer *dans quelle mesure la pollution atmosphérique historique explique la prévalence actuelle du cancer du poumon, indépendamment du tabagisme*. Il s’agit de dépasser les corrélations simplistes pour comprendre les dynamiques temporelles (latence biologique) et socio-économiques (biais de diagnostic) qui influencent les données observées.

1.3 Approche Méthodologique : Les Personas

Pour incarner cette analyse statistique et faciliter l’interprétation des résultats, deux profils théoriques ont été définis :

- **Marc (Le profil Tabac)** : 55 ans, réside en milieu rural, fumeur depuis 20 ans. Il pense : « Au moins, je ne respire pas les pots d’échappement des villes. »
- **Sarah (Le profil Pollution)** : 55 ans, non-fumeuse, vit au centre d’une métropole (Paris ou Pékin) depuis 20 ans. Elle pense : « Vivre ici, c’est comme fumer passivement, c’est inévitable. »

Ces personas permettent de contextualiser les résultats statistiques en termes d’exposition réelle et de risque individuel.

2 Méthodologie et Traitement des Données

2.1 Sources de Données

L’étude repose sur l’intégration de quatre bases de données internationales de référence :

1. **Banque Mondiale** : Indicateurs économiques, notamment le PIB par habitant.
2. **NASA / Data360** : Exposition annuelle moyenne aux particules fines PM_{2.5} (1990–2020).
3. **IHME (Global Burden of Disease)** : Prévalence du cancer du poumon et taux de tabagisme (2000–2020).
4. **Banque Mondiale (Tabac)** : Données historiques sur la consommation de tabac.

2.2 Préparation et Harmonisation des Données

2.2.1 Standardisation Géographique

Le premier défi méthodologique a été l’harmonisation des noms de pays entre les différentes sources de données. Les variations de nomenclature (« USA » vs « United States », « Corée du Sud » vs « Republic of Korea ») ont nécessité une normalisation systématique via les codes ISO-3 (FRA, USA, CHN). Cette standardisation a été réalisée à l’aide du package `countrycode` en R, garantissant la cohérence des jointures de données.

2.2.2 Restructuration Temporelle

Les données sur le tabagisme et le PIB, initialement présentées en format large (une colonne par année), ont été transformées en format long (une ligne par observation année-pays) pour faciliter l’analyse temporelle. Cette restructuration a été effectuée avec le package `tidyverse` en R.

2.2.3 Nettoyage

Un filtrage rigoureux a été appliqué pour éliminer les valeurs manquantes ou nulles, susceptibles de biaiser les analyses de corrélation.

2.3 Infrastructure Technique

L'ensemble de l'analyse a été réalisé sur Google Colab, permettant l'exécution de code R via rpy2. Les visualisations ont été produites avec ggplot2, et la manipulation de données a été effectuée avec tidyverse.

3 Identification et Correction des Biais Méthodologiques

3.1 Découverte du Biais de Diagnostic

Une première exploration de la prévalence mondiale du cancer du poumon a révélé une anomalie majeure : de très nombreux pays, principalement à faible revenu, affichaient des taux de prévalence quasi nuls. Cette observation a immédiatement soulevé l'hypothèse d'un **biais de diagnostic** plutôt que d'une absence réelle de pathologie.

3.2 Vérification de l'Hypothèse : PIB et Prévalence

Pour tester cette hypothèse, nous avons croisé la prévalence du cancer du poumon (2019) avec le PIB par habitant (2019). Les résultats ont confirmé une corrélation linéaire forte : plus un pays est riche, plus il « déclare » de cas de cancer du poumon. Cette relation s'explique par :

- La disponibilité d'équipements de diagnostic (scanners, IRM).
- L'accessibilité aux oncologues et aux centres spécialisés.
- La mise en place de programmes de dépistage systématique.
- La qualité des registres nationaux de santé.




FIGURE 1 – Corrélation entre le PIB par habitant et la prévalence déclarée du cancer du poumon (2019), illustrant le biais de diagnostic.




FIGURE 2 – Évolution de la prévalence du cancer du poumon de 1990 à 2020.

3.3 Décision Méthodologique : Filtrage par Richesse

Pour éviter le bruit statistique induit par ce biais de sous-diagnostic, nous avons décidé de **filtrer les données** et de ne conserver que les pays « fiables » ayant un PIB par habitant supérieur à 10 000 USD. Les pays en dessous de

ce seuil ont été exclus de l'analyse de corrélation. Cette décision, bien que réduisant la taille de l'échantillon, garantit une certaine validité interne des résultats.

4 Analyse des Corrélations : Les Paradoxes Temporels

4.1 Match 1 : L'Instantané (Année 2019)

En nous restreignant aux pays fiables, nous avons d'abord analysé les corrélations contemporaines (2019) entre les facteurs de risque et la prévalence du cancer du poumon.

4.2 Analyse Comparative des Facteurs de Risque (2019)

Dans cette section, nous confrontons les deux principaux facteurs de risque étudiés, le tabagisme et la pollution atmosphérique, à la prévalence du cancer du poumon pour l'année 2019.




FIGURE 3 – Match Tabac vs Cancer (2019). Corrélation $R = 0,32$.




FIGURE 4 – Match Pollution vs Cancer (2019). Corrélation $R = -0,54$.

4.2.1 Interprétation des Résultats Contemporains

Le facteur Tabac ($R = 0,32$) : Contrairement aux premières observations mondiales brutes, l'analyse sur les pays ciblés révèle une corrélation positive modérée de 0,32. Ce résultat indique que le taux de tabagisme actuel commence à expliquer une partie de la prévalence du cancer, même si l'effet complet reste atténué par la latence biologique (le cancer d'aujourd'hui étant le produit de la consommation passée).

Le paradoxe de la Pollution ($R = -0,54$) : Le résultat pour la pollution reste paradoxal avec une corrélation négative marquée. Ce chiffre suggère que les pays affichant les taux de pollution les plus bas en 2019 sont ceux qui déclarent le plus de cancers. Cette observation confirme l'influence de deux facteurs majeurs :

- **Le Biais de richesse :** Les nations développées disposent de systèmes de diagnostic plus performants tout en ayant déjà amorcé leur transition écologique pour réduire les PM2.5.
- **La Latence temporelle :** La pathologie actuelle reflète l'exposition à la pollution industrielle intense des décennies 1970-1990, période où ces pays étaient nettement plus pollués.

4.3 Match 2 : Test de l'Hypothèse de Latence (1990 vs 2019)

Pour valider l'hypothèse de la mémoire biologique, nous avons décalé l'analyse temporelle en comparant la pollution de 1990 avec la prévalence du cancer de 2019.




FIGURE 5 – Test de latence : Impact de la pollution historique (1990) sur la prévalence actuelle.

Résultat : Résultat : La corrélation est moins négative que dans l'analyse contemporaine ($R = 0,35$ contre $0,54$ en 2019), ce qui suggère que l'exposition passée est plus informative que l'exposition mesurée la même année

Interprétation : Cette évolution est compatible avec une latence longue : l'effet sanitaire des PM2.5 résulte d'expositions cumulées sur plusieurs décennies.

Limites d'interprétation : Le signe négatif persistant s'explique vraisemblablement par des facteurs structurels : les pays les plus développés déclarent davantage de cancers (meilleure détection) et ont, pour beaucoup, réduit leur pollution depuis les années 1990. De plus, la latence varie selon les pays (durée et intensité d'exposition, structure d'âge, cofacteurs), rendant un décalage temporel unique imparfait. Le décalage temporel améliore la cohérence, mais ne permet pas d'identifier un effet net de la pollution sans contrôle explicite des facteurs de confusion.

4.4 Match 3 : Le Cas « Sarah » (Focus Féminin)

Afin d'isoler l'impact de la pollution du bruit causé par le tabac (historiquement plus consommé par les hommes), nous avons concentré l'analyse sur la population féminine. Nous avons corrélié la pollution atmosphérique de 1990 avec la prévalence du cancer du poumon chez les femmes en 2019.




FIGURE 6 – Le cas Sarah : Corrélation entre la pollution historique et le cancer féminin.

Résultat : $R = -0.41$.

Interprétation : Bien que le biais de diagnostic (richesse) reste dominant, l'évolution des coefficients de corrélation confirme que la pollution historique est un facteur sous-jacent que le tabac tend à masquer chez les hommes. Cette approche permet d'observer l'impact environnemental « pur » avec moins d'interférences liées au mode de vie.

5 Segmentation et Clustering : Cartographie des Profils de Risque

5.1 Méthodologie de Classification

Pour synthétiser les résultats et identifier des profils nationaux distincts, nous avons procédé à une classification des pays en quatre clusters, basée sur les valeurs médianes de tabagisme et de prévalence du cancer du poumon.

5.2 Les Quatre Clusters Identifiés

1. **Cluster Sain (Vert)** : Faible tabagisme / Faible prévalence de cancer.
 - Profil : Pays ayant maintenu des politiques de santé publique strictes et un environnement peu pollué.
 - Exemple typique : Pays scandinaves avec réglementation précoce du tabac.
2. **Cluster Marc (Rouge)** : Fort tabagisme / Forte prévalence de cancer.
 - Profil : Lien de causalité classique confirmé. Ces pays accumulent l'impact du tabagisme historique.
 - Exemple typique : Pays d'Europe de l'Est avec forte consommation de cigarettes dans les années 1980–2000.
3. **Cluster Résistance (Bleu)** : Fort tabagisme / Faible prévalence de cancer.
 - Profil : Paradoxe statistique suggérant principalement un effet de latence, un sous-diagnostic résiduel, ou des différences de structure démographique et de dépistage.
 - Exemple typique : Certains pays asiatiques avec forte consommation de tabac mais diagnostic récent.
4. **Cluster Sarah (Orange)** : Faible tabagisme / Forte prévalence de cancer.
 - Profil : Anomalie statistique majeure. Ces pays présentent des taux de cancer élevés malgré un tabagisme limité.
 - Hypothèse principale : Pollution atmosphérique historique intense (industrialisation rapide).
 - Exemples typiques : Corée du Sud, Pologne (PM2.5 historique > 25 $\mu\text{g}/\text{m}^3$).




FIGURE 7 – Cartographie des clusters de risque (Tabac vs Cancer) et identification du Cluster Sarah.

6 Interprétations et Cas Nationaux

Cas : Corée du Sud, Pologne

Ces pays présentent un tabagisme moyen mais une exposition historique aux PM2.5 très élevée (> 25 $\mu\text{g}/\text{m}^3$ dans les années 1990). L'industrialisation rapide et l'urbanisation massive ont créé des environnements urbains chroniquement pollués. L'exposition urbaine prolongée a « compensé » l'absence relative de cigarette, générant des taux de cancer comparables à ceux des pays à fort tabagisme.

Cas : Australie, Islande

Ces pays affichent des taux de cancer élevés malgré un air exceptionnellement pur et un tabagisme faible. Ce paradoxe s'explique par un système de santé ultra-performant qui détecte chaque cas, même chez les non-fumeurs et même à des stades précoces. La prévalence reflète ici la qualité du système de détection plutôt que la sévérité de l'exposition.

7 Synthèse Statistique

Le tableau ci-dessous résume l'ensemble des analyses de corrélation effectuées :

Modèle d'Analyse	Coefficient R	Verdict
Tabac (2019)	0.32	Corrélation mais masqué par la latence
Pollution (2019)	-0.54	Biais de richesse dominant
Pollution (1990)	-0.35	Confirmation de l'hypothèse de latence
Cas Sarah (Femmes 1990)	-0.41	Poids du biais diagnostique majeur

TABLE 1 – Résumé des coefficients de corrélation selon les modèles analysés

8 Discussion et Limites

8.1 Apports Principaux

Cette étude démontre qu'il est impossible d'analyser le cancer du poumon sans prendre en compte deux dimensions fondamentales :

1. **Le décalage temporel (latence)** : Le cancer est le résultat d'expositions survenues 20 à 30 ans plus tôt. Les analyses synchrones (même année) sont trompeuses.
2. **Le biais économique de détection** : Les pays pauvres sous-diagnostiquent massivement le cancer, créant une corrélation artificielle entre richesse et prévalence déclarée.

8.2 Limites Méthodologiques

8.2.1 Approche Macroscopique

L'étude repose sur des moyennes nationales qui masquent les inégalités régionales et les expositions locales. Un habitant de la vallée de l'Arve (France) n'est pas exposé aux mêmes niveaux de pollution qu'un habitant de la Bretagne.

Le seuil de 10 000 USD, bien que justifié, demeure insuffisant. Certains pays à revenus intermédiaires peuvent avoir des systèmes de santé performants dans des zones urbaines, tandis que des pays riches peuvent présenter des inégalités d'accès au diagnostic.

8.2.2 Modélisation par Régression Multiple

Une analyse multivariée intégrant simultanément le tabagisme, la pollution, le PIB, et d'autres variables (densité urbaine, qualité des soins) permettrait de quantifier la part de variance expliquée par chaque facteur.

8.2.3 Approche Régionale

Une étude à l'échelle infra-nationale (régions, villes) permettrait de mieux contrôler les effets de richesse et d'isoler l'impact de la pollution locale.

9 Conclusion Générale

Cette étude, fondée sur des données issues de la Banque mondiale, de la NASA/Data360 et de l'IHME, avait pour objectif d'évaluer le rôle de la pollution atmosphérique dans la prévalence du cancer du poumon, indépendamment du tabagisme. Les résultats confirment que le tabac demeure le principal facteur de risque individuel, tout en montrant que l'effet propre de la pollution est difficile à isoler à partir de comparaisons internationales simples.

Les corrélations contemporaines produisent des résultats paradoxaux, parfois négatifs, principalement en raison d'un biais structurel : les pays à haut niveau de développement diagnostiquent davantage de cancers (prévalence déclarée plus élevée) tout en ayant, pour beaucoup, réduit leur pollution atmosphérique récente. L'introduction d'un décalage temporel entre l'exposition à la pollution et l'incidence actuelle du cancer améliore la cohérence des résultats, mais ne suffit pas à éliminer l'ensemble des biais.

Ainsi, nos analyses ne permettent ni d'établir une relation causale, ni de quantifier précisément l'effet spécifique de la pollution atmosphérique sur le cancer du poumon à l'échelle mondiale. Les principales limites identifiées sont le biais de diagnostic lié au niveau de développement, la latence variable des cancers selon les contextes nationaux, ainsi que la présence de nombreux facteurs confondants insuffisamment contrôlés (tabagisme passé, structure d'âge, politiques de dépistage, expositions professionnelles, entre autres).

Ces résultats suggèrent que l'impact de la pollution atmosphérique sur le cancer du poumon, bien que biologiquement plausible et soutenu par la littérature, ne peut être correctement estimé à l'aide de corrélations simples. Il nécessite des approches statistiques plus sophistiquées, intégrant les dynamiques temporelles et les déterminants structurels de la santé.

Pour Marc, fumeur en milieu rural, le message reste sans ambiguïté : le tabac demeure l'ennemi principal, et ses effets se manifesteront souvent des décennies plus tard. Pour Sarah, citadine non-fumeuse, l'inquiétude est également fondée : respirer l'air d'une grande métropole pendant vingt ans correspond à une exposition toxique chronique dont les conséquences sanitaires sont réelles et documentées.

La prévention future du cancer du poumon repose donc sur une double stratégie : poursuivre sans relâche la lutte contre le tabagisme tout en renforçant les politiques de qualité de l'air. Car les cancers d'aujourd'hui sont le produit de la pollution d'hier, et ceux de demain se construisent dans l'air que nous respirons aujourd'hui.