





PRÉDICTION DE L'INSUFFISANCE CARDIAQUE



-  **Louaï HAMLAT**
-  **Sofia FRANCHI**
-  **Jianghan WANG**

L'Insuffisance Cardiaque : Un fardeau mondial et national

64M


Personnes touchées - Monde

1,5M

Personnes touchées - France

70k

Décès annuels en France



⚠ Limites Actuelles

- **Diagnostic tardif** : Souvent détecté à un stade avancé.
- **Coût élevé** : Hospitalisations récurrentes et onéreuses.
- **Invasivité** : Examens de référence (coronarographie) coûteux et invasifs.

🧠 L'Approche Prédictive

- **Variables de routine** : Utilisation de données cliniques standard.
- **Stratification précoce** : Identifier les patients à risque dès le premier contact.
- **Optimisation** : Personnalisation du parcours de soin et réduction de la mortalité.



Dans quelle mesure l'apprentissage automatique peut-il prédire le risque cardiaque à partir de données de routine, et quels déterminants cliniques prévalent dans cette prédiction ?



Design et données de l'étude



Base de données multicentrique

Fusion de 5 banques de données internationales :

- Cleveland, Hungarian, Switzerland, Long Beach, Stalog.
- **Volume** : 918 observations.
- **Structure** : 11 variables explicatives.

Note : Cohorte masculine à 79% (limite de généralisation).

Variable	Type	Description	Domaine
Age	Continue	Âge du patient	[28, 77] ans
Sex	Binaire	Sexe	{ <i>M</i> , <i>F</i> }
ChestPainType	Catégoriel (4)	Type de douleur thoracique	{ <i>TA</i> , <i>ATA</i> , <i>NAP</i> , <i>ASY</i> }
RestingBP	Continue	Tension systolique au repos	[0, 200] mmHg
Cholesterol	Continue	Cholestérol sérique	[0, 603] mg/dl
FastingBS	Binaire	Glycémie à jeun élevée	{0, 1}
RestingECG	Catégoriel (3)	ECG de repos	{ <i>Normal</i> , <i>ST</i> , <i>LVH</i> }
MaxHR	Continue	Fréquence cardiaque maximale	[60, 202] bpm
ExerciseAngina	Binaire	Angine d'effort	{ <i>Y</i> , <i>N</i> }
Oldpeak	Continue	Dépression ST à l'effort	[0, 6.2] mV
ST_Slope	Catégoriel (3)	Pente du segment ST	{ <i>Up</i> , <i>Flat</i> , <i>Down</i> }
HeartDisease	Binaire	Diagnostic	{0, 1}



Gestion de la Qualité des Données



Exclusion

RestingBP : 1 observation avec une valeur de 0 (incompatible physiologiquement) a été exclue.



Conversion

Cholestérol : 172 valeurs à 0 mg/dl (19% de l'échantillon) converties en valeurs manquantes (NaN).



Imputation

Médiane : Remplacement des NaN par la médiane pour préserver la puissance statistique du modèle.



Méthodes



Apprentissage **supervisé** (données étiquetées)

- variable cible : HeartDisease - qualitative binaire

Split train - test stratifié :

- 80% - 20%

Choix des modèles :

- Regression logistique (baseline statistique)
- KNN (classification par voisinage)
- Random Forest (interactions non linéaires)
- XGBoost (gradient boosting)

Grille de recherche (grid search)


Pipeline de preprocess :

- Variables qualitatives : Imputation (SimpleImputer) => Encodage (One hot)
- Variables quantitatives : Imputation (SimpleImputer) => Normalisation (RobustScaler)


Cross Validation :

- Stratified K fold : 5 splits, shuffled,
- Métriques (scoring) : Accuracy, Precision, Recall, F1-score, AUC-ROC
- Critère pivot (refit) : ROC-AUC vs Recall

Maitriser le risque de data leakage



Resultats apprentissage





LR et KNN

Bon apprentissage des deux modèles.
Bonne capacité à généraliser.
Le jeu de données semble suffisant.

RF et XGB

Surapprentissage des deux modèles.
Généralisation limitée.
Le jeu de données semble insuffisant.


Performance des Meilleurs Estimateurs



Resultats


Les courbes de ROC sont **similaires** pour l'ensemble des modèles.

Le KNN semble meilleur que le LR sur les métriques, cependant il a une **log_loss** plus importante.



Modèle retenu :
Régression Logistique

- Pas d'overfitting
- Log_loss plus faible




Interprétabilité des modèles


Variables les plus discriminantes

Impact individuel des variables

Exploration des variables qualitatives



SHAP Summary Plot - XGB



- ST_Slope (pente du segment ST) : La pente "Flat" ou "up" est le facteur le plus discriminant (indique une ischémie myocardique).
- ChestPainType (type de douleur thoracique) : Le type "ASY" (asymptomatique) est extrêmement risqué (fort corrélation avec la maladie cardiaque).
- ExerciseAngina (angine induite par l'effort) : Présence (Yes) = risque majoré.
- Âge : Augmentation linéaire du risque avec l'âge.
- MaxHR (fréquence cardiaque maximale) : Valeurs basses associées à un risque plus élevé.



Discussion



Compromis :

Modèle	ROC-AUC	Recall (sensibilité)
XGBoost	0.88	89%
Forêt aléatoire (RF)	0.87	87%
Régression logistique	0.85	86%
KNN	0.82	83%

augmenter la complexité du modèle n'améliore pas significativement la performance diagnostique

Complexité vs Performance

Le gain marginal des modèles complexes (XGBoost) par rapport à la Régression Logistique est faible.
L'explicabilité native de la LR est un atout majeur en clinique.

Limites de l'Étude

Biais de genre (79% hommes), biais de centre dû à la fusion de cohortes, et absence de validation externe sur des données hospitalières contemporaines.

Conclusion

- Risque cardiaque **prédictible** avec **données cliniques simples** (AUC-ROC 0.82-0.88)
- Variables clés : ST_Slope, ChestPainType, ExerciseAngina, Âge, MaxHR (clinique-cohérentes)
- **Régression logistique** : outil de choix pour santé publique (simple + interprétable)
- Biais cohorte → validation externe nécessaire




Nada Ikram Boudegzdame, Ivan Lerner,
Bastien Rance


ANNEXES

Details méthodologiques


Objectif : Nous voulons être en mesure de comparer les différents modèles dans les mêmes conditions et sans 'data-leakage'.



Importance des variables : LR
(Odds Ratios)



SHAP Summary Plot - LR



Feature Importance Comparison (MDI & MDA)

